

Scientific Computation

Prof. Matthew Giamou
Oct. 23, 2025

Lecture 17 - Least Squares

Lecture Outline

- Linear least squares

- Underdetermined system
- Computing eigenvalues

Regression

Recall our formulation of linear regression:

$$\min_z \left\| \begin{bmatrix} \phi_1(x_0) & \phi_2(x_0) & \cdots & \phi_m(x_0) \\ \phi_1(x_1) & \phi_2(x_1) & \cdots & \phi_m(x_1) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_1(x_n) & \phi_2(x_n) & \cdots & \phi_m(x_n) \end{bmatrix} z - \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{bmatrix} \right\|^2,$$

where $\phi_1(x) = x$ and $\phi_2(x) = 1$.

Leads to linear regression

Choice of Basis Functions

An important point must be made: even when the choice of basis functions ϕ_i is nonlinear, this still results in a linear problem!

$$Az = \begin{bmatrix} \phi_1(x_0) & \phi_2(x_0) & \cdots & \phi_m(x_0) \\ \phi_1(x_1) & \phi_2(x_1) & \cdots & \phi_m(x_1) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_1(x_n) & \phi_2(x_n) & \cdots & \phi_m(x_n) \end{bmatrix} z = y,$$

↳ we'll select nonlinear ϕ_i 's today

↳ Our formulation of regression is similar to interpolation


4


Polynomial Regression

Example 2: Let's fit a data set of 4 points with a quadratic polynomial:

$x_i:$ 1 2 3 4

$y_i:$ 1 2 2 1.5





A Monomial Basis

Example 2 cont.: We'll use the simple monomial basis

$$\phi_1(x) = 1, \phi_2(x) = x, \phi_3(x) = x^2,$$

which leads to the system

$$\min_z \left\| \begin{bmatrix} 1 & x_0 & x_0^2 \\ 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \end{bmatrix} z - \begin{bmatrix} y_0 \\ y_1 \\ y_2 \\ y_3 \end{bmatrix} \right\|^2$$


A

We solve $A^T A z = A^T y \Rightarrow z = (A^T A)^{-1} A^T y$


6

Polynomial Regression Results

Example 2 cont.: This is just a few lines of code in Julia:



```
using Plots
x = [1; 2; 3; 4]
y = [1; 2; 2; 1.5]
n = length(x)
A = [ones(n) x x.^2]
display(A)
```



```
display(A)
c = A\y
x_plot = 0:0.01:4.0
p(x) = c[1] + c[2]*x + c[3]*x^2
scatter(x, y, label="Dataset",
        markersize=5, color=:black)
plot!(x_plot, p.(x_plot),
        label="Best Quadratic Fit",
        color=:red, linestyle=:dash)
```

✓ 0.0s

4×3 Matrix{Float64}:

1.0	1.0	1.0
1.0	2.0	4.0
1.0	3.0	9.0
1.0	4.0	16.0

7

Lecture Outline

- Linear least squares
- Underdetermined systems
- Computing eigenvalues

Less Points Than Parameters

LESS EQUATIONS THAN PARAMETERS

What if $n > m$ for $Ax = b$ where $A \in \mathbb{R}^{m \times n}$? This is a “wide” matrix, e.g.:

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}.$$

We have more unknowns than equations! This is called an **underdetermined system** because there are not enough constraints to force a **unique** solution.

So there are infinitely many solutions

9

$$x^T \lambda I x = \|x\|^2 \cdot \lambda > 0$$

A Solution: Regularization

One solution is to perform L^2 regularization:

$$x^T A^T A x$$

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|^2 + \lambda \|x\|_2^2, \quad (Ax)^T Ax \geq 0$$

where $\lambda > 0$ is a controllable parameter. This gives us a unique solution for each λ by encouraging values of x that have a small L^2 (Euclidean) norm.

$$\begin{aligned} \text{Cost } f(x) &= \|Ax - b\|^2 + \lambda \|x\|^2 \\ &= x^T (A^T A + \lambda I) x - 2x^T A^T b + \|b\|^2 \end{aligned}$$

$$\nabla f(x) = 2(A^T A + \lambda I) x - 2A^T b = 0$$

$$\Rightarrow x = \underbrace{(A^T A + \lambda I)^{-1}}_{\text{regularized inverse}} A^T b$$

$\swarrow$
 $\text{PSD} \rightarrow \text{quite similar to pseudo inverse}$
 $\searrow$
 $\text{PD} \Rightarrow \text{invertible}$

10

No Tolerance for Error

What if we want to choose one of the solutions that exactly satisfies $Ax = b$? We can try **constrained optimization**:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \|x\|^2 \\ \text{s.t. } Ax = b \end{aligned}$$

This approach selects the value of x with minimal squared L^2 norm from the feasible set for $Ax = b$.

We would solve this is with **Lagrange multipliers**
 $\lambda \in \mathbb{R}^n$

$$L(x, \lambda) = \|x\|^2 + \lambda^T (Ax - b)$$

$$\text{solve } \nabla_{x, \lambda} L(x, \lambda) = 0.$$

$$\nabla_x L = -\frac{1}{2} A^T \lambda$$

$$\nabla_\lambda L = -2(AA^T)^{-1}b$$

$$x = A^T(AA^T)^{-1}b$$

11


Visualizing Underdetermined Systems

Consider $Ax = b$ for $A = [1 \ 1]$ and $b = 1$:

1



$$\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 1$$



$$x_1 + x_2 = 1$$


Let's look at L_2 regularized solutions.

$$\min_x \|Ax - b\|_2^2 + \lambda \|x\|_2^2$$

What does the solution look like as a function of λ ? ($\lambda > 0$)

12

Visualizing Underdetermined Systems with Julia



```
using LinearAlgebra
using Plots
A = [1 1]
b = 1
lambda_vals = 0.01:0.01:1.0

f(lambda) = inv(A'A + lambda*I)*A'b
x = zeros(length(lambda))
y = zeros(length(lambda))
for (i, lambda) in enumerate(lambda_vals)
    v = f(lambda)
    x[i] = v[1]
    y[i] = v[2]
end
x_range = 0:0.1:1.0
plot(x, y, label="Regularized Solutions",
      color=:red)
plot!(x_range, 1 .- x_range, label="Ax=b",
      color=:blue)
```

13

Lecture Outline

- Linear least squares
- Underdetermined systems
- **Computing eigenvalues**

Important Eigenvalues

In many applications, it is the *extremal* (algebraically largest or smallest) eigenvalues that are most important. For example, take diagonal matrices

$$A = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix},$$

whose eigenvalues are the diagonal elements. Suppose $|\lambda_1| \gg |\lambda_2|$.

$$Ax = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} \lambda_1 x_1 \\ \lambda_2 x_2 \end{bmatrix} \approx \begin{bmatrix} \lambda_1 x_1 \\ 0 \end{bmatrix}$$

We see that Ax mostly depends on x_1 , i.e. on the part of x that comes from eigenvector $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$

corresponding to eigenvalue λ_1 .

15

Finding Extremal Eigenvalues

Finding all the eigenvalues of $A \in \mathbb{R}^{n \times n}$ is akin to inverting the matrix and takes $O(n^3)$. We would hope that there are computationally efficient ways of finding just the extremal eigenvalues of interest! Consider the eigenpairs (λ_i, x_i) of A , and suppose the largest (in magnitude) eigenvalue is $\lambda_1 \in \mathbb{R}$.

i.e. $|\lambda_1| \geq |\lambda|$ for all $\lambda \in \sigma(A)$ *spectrum of A*
= set of eigenvalues

Assume A has n linearly indep. eigenvectors $\Leftrightarrow A$ is diagonalizable

$A = P \Lambda P^{-1}$ for P consisting of eigenvectors of A , $\Lambda = \text{diag}([\lambda_1, \dots, \lambda_n])$

$\Rightarrow$ Any $v \in \mathbb{R}^n$ can be written as
$$v = \sum_{j=1}^n \alpha_j x_j$$
 where $\alpha_j \in \mathbb{R}$
and x_i are eigenvectors of A

16

The Power Method

With this decomposition of v , apply A to v multiple times in succession, i.e.,

$$Av, A^2v, \dots, A^k v.$$

This gives us:

$$A^k v = A^k \sum_{j=1}^n \alpha_j x_j = \sum_{j=1}^n \alpha_j A^k x_j = \sum_{j=1}^n \alpha_j \lambda_j^k x_j$$

$$Av = \sum_{j=1}^n \alpha_j \lambda_j x_j = \sum_{j=1}^n \alpha_j \lambda_j^2 x_j$$

$$A^2 v = A(Av) = A \sum_{j=1}^n \alpha_j \lambda_j^2 x_j = \sum_{j=1}^n \alpha_j \lambda_j^4 x_j$$

$$\vdots$$

$$A^k v = \sum_{j=1}^n \alpha_j \lambda_j^k x_j$$

Note: the indices λ_j correspond to descending, i.e. $|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n|$

17

The Power Method Cont.

We can factor

$$A^k v = \lambda_1^k \alpha_1 x_1 + \lambda_2^k \alpha_2 x_2 + \dots + \lambda_n^k \alpha_n x_n$$

to get

$$A^k v = \lambda_1^k \left(\alpha_1 x_1 + \left(\frac{\lambda_2}{\lambda_1} \right)^k \alpha_2 x_2 + \dots + \left(\frac{\lambda_n}{\lambda_1} \right)^k \alpha_n x_n \right)$$

$$\text{if } |\lambda_1| > |\lambda_j|, \forall j, \text{ then } \left| \frac{\lambda_j}{\lambda_1} \right|^k \rightarrow 0 \text{ as } k \rightarrow \infty$$

$\hookrightarrow$ i.e. largest magnitude eigenvalue is unique (has algebraic multiplicity of 1)

Then $A^k v \rightarrow (\lambda_1^k \alpha_1) x_1$, as $k \rightarrow \infty$.

So, $A^k v$ converges to a multiple of x , which is the eigenvector of λ_1 .

18

Rate of Convergence and Over/Underflow

What is the slowest term to vanish as $k \rightarrow \infty$?

$\left(\frac{\lambda_2}{\lambda_1}\right)^k$ because $|\lambda_2|$ is second largest.

So this ratio controls the convergence rate.

Also, if $|\lambda_1| > 1$, $A^k v \approx (\lambda_1^k \alpha_1) x$, so watch out for overflow!

Like wise. if $|\lambda_1| < 1$, $A^k v$ can underflow

Solution: Normalized! $\tilde{V}_{k+1} = AV_k$

$$V_{k+1} = \frac{\tilde{V}_{k+1}}{\|\tilde{V}_{k+1}\|_2}$$
} This works because only direction matters for eigenvectors

19

Power Method Example

Example 1: Recall the simple diagonal matrix

$$A = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix},$$

where $|\lambda_1| > |\lambda_2|$. Let $v = [1 \ 1]^T$.

$$Av = \begin{bmatrix} \lambda_1 \\ \lambda_2 \end{bmatrix}, A^2v = \begin{bmatrix} \lambda_1^2 \\ \lambda_2^2 \end{bmatrix}, \dots, A^k v = \begin{bmatrix} \lambda_1^k \\ \lambda_2^k \end{bmatrix} \approx \begin{bmatrix} \lambda_1^k \\ 0 \end{bmatrix}$$

Food for thought: what if $v = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$, which is orthogonal to eigenvector x_1 ?

之前我们讲了对于 $m \times n$ 的矩阵 A ，当 $m > n$ 的情况我们可以使用pseudo inverse来处理，那么对于 $n > m$ 的情况（无穷个解）我们也有相应的解决办法。

1) 问题与目标

给定 $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, 我们不是单纯最小化残差 $\min_x \|Ax - b\|^2$, 而是加上对系数大小的惩罚:

$$\min_{x \in \mathbb{R}^n} f(x) = \|Ax - b\|^2 + \lambda \|x\|^2, \quad \lambda > 0.$$

- 第1项让拟合好数据；第2项鼓励系数变小，抑制过拟合/病态放大。
- 这等价于“在所有解中选一个范数小的”。

2) 推导（图中黑字的计算）

展开目标：

$$f(x) = (Ax - b)^\top (Ax - b) + \lambda x^\top x = x^\top A^\top A x - 2x^\top A^\top b + b^\top b + \lambda x^\top x.$$

求梯度并令零：

$$\nabla f(x) = 2(A^\top A + \lambda I)x - 2A^\top b = 0 \Rightarrow (A^\top A + \lambda I)x = A^\top b.$$

于是得到闭式解（蓝色方框）：

$$x = (A^\top A + \lambda I)^{-1} A^\top b.$$

3) 为什么一定“可逆、唯一”（图中紫/蓝批注）

- $A^\top A$ **半正定** (PSD) : $x^\top A^\top A x = \|Ax\|^2 \geq 0$.
- 加上 λI ($\lambda > 0$) 后, 所有特征值都向右平移 λ :
 $\lambda_i(A^\top A + \lambda I) = \lambda_i(A^\top A) + \lambda > 0$.
 所以它是**正定** (PD) $\Rightarrow$ 一定可逆 $\Rightarrow$ 解**唯一**.

4) 与伪逆的关系 (图中红字 “similar to pseudoinverse”)

- 普通最小二乘: $x = A^+b = (A^T A)^{-1} A^T b$ (当 $A^T A$ 可逆)。
- 岭回归: $x_\lambda = (A^T A + \lambda I)^{-1} A^T b$ 。
- 当 $\lambda \rightarrow 0^+$ 时, $x_\lambda \rightarrow A^+b$; 当 A 退化或病态时, 加 λI 起到了“稳定化”的作用。

SVD 视角 (收缩解释)

若 $A = U \Sigma V^T$, 则

$$x_\lambda = V \operatorname{diag}\left(\frac{\sigma_i}{\sigma_i^2 + \lambda}\right) U^T b.$$

每个奇异值方向的增益从 $1/\sigma_i$ 变成 $\sigma_i/(\sigma_i^2 + \lambda)$:

- 小 σ_i 的方向被强烈“收缩” (抑制噪声放大) ;
- 大 σ_i 的方向基本保留信息。

5) 几何与等价观点

- **偏差-方差权衡**: λ 大 $\Rightarrow$ 系数更小、更平滑、方差小; λ 小 $\Rightarrow$ 拟合更强、方差大。
- **约束式等价** (拉格朗日对偶) :

$$\min \|Ax - b\|^2 \text{ s.t. } \|x\|^2 \leq \tau \quad \Longleftrightarrow \quad \min \|Ax - b\|^2 + \lambda \|x\|^2$$

对应某个 $\lambda \leftrightarrow \tau$ 。

6) 极限与特殊情形

- $\lambda \rightarrow 0$: 回到普通最小二乘/伪逆。
- $\lambda \rightarrow \infty$: $x_\lambda \rightarrow 0$ (完全正则化)。
- **欠定** ($m < n$) : x_λ 仍唯一; 当 $\lambda \rightarrow 0$ 时, x_λ 收敛到 **最小范数解** $A^T(AA^T)^{-1}b$ 。

下一张图展示了所有满足要求的点都在蓝线上, $\|Ax-b\|^2$ 保证拟合数据 (靠近蓝线), 第二项 $\lambda \|x\|^2$ 惩罚 x 太大 (让解靠近原点), $\lambda > 0$ 是控制这两者平衡的参数。 λ 大于 0 是保证 $A^T A + \lambda I$ 可逆。

第二部分是关于最大和最小特征值。

matrix 的 extremal eigenvalues 就是数值最大和最小的 eigenvalue, 因为他们主导了 matrix 变换的行为。

所以我们的例子里 λ_1 远大于 2, 那么 $Ax \approx [\lambda_1 x_1, 0]^T$, 即对应于最大的 eigenvalue 的 eigenvector 方向。

1 为什么我们只关心极端特征值?

计算一个 $n \times n$ 矩阵的所有特征值（比如通过特征分解或 QR 算法）需要 $O(n^3)$ 的时间复杂度。

👉 对大型矩阵来说非常贵。

但是在很多应用里，我们只需要：

- 最大的特征值 (by magnitude)
- 或 最小的特征值

例如：

- 在PCA里我们只关心最大的；
- 在稳定性分析里可能关心最小的；
- 在幂法 (Power Method) 或 迭代法中，我们只找主特征值。

2 特征对 (Eigenpairs)

我们设矩阵 A 的特征对是 (λ_i, x_i) ：

$$Ax_i = \lambda_i x_i$$

假设最大的特征值（按绝对值）是：

$$|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$$

3 术语解释

笔记中有一句：

$$|\lambda_1| > |\lambda| \text{ for all } \lambda \in \sigma(A)$$

这里：

- $\sigma(A)$ ：表示 A 的谱 (spectrum)，即所有特征值的集合；
- 这句话意思是：
 λ_1 是所有特征值中绝对值最大的一个。

4 假设：A 可对角化 (Diagonalizable)

Assume A has n linearly independent eigenvectors
 $\Leftrightarrow$ A is diagonalizable

这意味着我们可以写成：

$$A = P \Lambda P^{-1}$$

其中：

- P ：由所有特征向量 $x_1, x_2, \dots, x_n$ 组成；
- $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ ：对角矩阵，包含所有特征值。

5 任意向量的分解 (Expansion)

任何向量 $v \in \mathbb{R}^n$ 都可以用特征向量的线性组合来表示：

$$v = \sum_{j=1}^n \alpha_j x_j$$

其中：

- $\alpha_j \in \mathbb{R}$ ：是对应特征向量方向的系数；
- x_j ：是 A 的特征向量。

这个意思是，矩阵 A 有 n 个 eigenvector，所以可以表示 $\mathbb{R}^n$ 的向量。同时，我们分析 $A^k v$ 最后会得到近似于 $\alpha_1 \lambda_1^k x_1$ ，完全被最大的 eigenvalue 主导。

但是这个过程的收敛速度取决于第二大的 eigenvalue λ_2 ，所以**收敛速率正比于** $\left| \frac{\lambda_2}{\lambda_1} \right|$

由于每次都在做：

$$v_{k+1} = A v_k$$

而 $A^k v_0 \approx \lambda_1^k x_1$ ，

所以分量会像 λ_1^k 一样增长或衰减。

✅ 如果 $|\lambda_1| > 1$ ：

→ 每次乘都会让结果越来越大 → **数值溢出 (overflow)**

✅ 如果 $|\lambda_1| < 1$ ：

→ 每次乘都会让结果越来越小 → **数值下溢 (underflow)**

两种情况都会让计算不稳定。

💡 五、解决方案：归一化 (Normalization)

我们只关心方向（因为特征向量只在方向上定义，不在长度上定义），所以可以每步都把结果“归一化”：

$$\tilde{v}_{k+1} = Av_k$$

$$v_{k+1} = \frac{\tilde{v}_{k+1}}{\|\tilde{v}_{k+1}\|_2}$$

这样：

- 保证向量的长度始终为 1；
- 消除了 λ_1^k 带来的爆炸或消失；
- 仍然保持方向的收敛。

这就是图里紫色字那句：

“This works because only direction matters for eigenvectors.”

关于什么时候会converge到最大的eigenvalue对应的eigenvector上：如果初始的向量x和extremal eigenvector是orthogonal的，那么就只会converge到第二大的eigenvector上。

关于 Lagrangian Multiplier:

它的核心思想是把一个**有约束**的优化问题，巧妙地“转换”成一个**没有约束**的新问题。如果说 $A^+ = (A^T A)^{-1} A^T$ 是解决无解方程组的，那么L就是来解决无穷解方程组的。我们在优化目标里引入了 λ ，这个 λ 是为了防止过拟合让得到的多项式变的特别复杂。 λ 很小就是更接近interpolation， λ 更大说明要更低的复杂度。为了找到最小值 $\min f(x)$ ， λ 就是我们的约束项。于是我们引入L，对他的x和 λ 分别求偏导，让其=0就是优化方法。

- 对于 overdetermined system，没有解，所以我们用least square找最接近的拟合，此时 pseudoinverse是 $A^+ = (A^T A)^{-1} A^T$
- 对于 underdetermined system，无数个解，我们想找最简单的解（约束 lambda），所以我们用 L，此时pseudoinverse是 $A^+ = A^T (A A^T)^{-1}$

$$\mathcal{L}(x, \lambda) = \|x\|^2 + \lambda^T (Ax - b)$$

- 这是什么？这就是我们构造的拉格朗日函数 (Lagrangian Function)。
- $\|x\|^2$ ：这是我们的目标函数 $f(x)$ ，即我们想要最小化的东西（解的“简单程度”）。
- $(Ax - b)$ ：这是我们的约束 $g(x)$ 。我们被“硬约束”规定，这一项必须等于 0。

- λ^T 。这个拉格朗日系数 λ 是一个“软”的未知量，我们可以在后面